

UNIVERSIDADE FEDERAL DE UBERLÂNDIA
FACULDADE DE ENGENHARIA ELÉTRICA – PATOS DE MINAS
ENGENHARIA ELETRÔNICA E DE TELECOMUNICAÇÕES

HEITOR FERREIRA CAMARGOS SILVA

**SISTEMA AUTOMATIZADO DE TOMADA DE DECISÃO EM UM
JOGO DE POKER**

Patos de Minas - MG

2018

HEITOR FERREIRA CAMARGOS SILVA

SISTEMA AUTOMATIZADO DE TOMADA DE DECISÃO EM UM JOGO DE POKER

Trabalho de Conclusão de Curso 2
apresentado à banca examinadora como
pré-requisito para obtenção do título de
bacharel em Engenharia Eletrônica e de
Telecomunicações, na Faculdade de
Engenharia Elétrica, da Universidade
Federal de Uberlândia, Campus Patos de
Minas.

Orientador: Prof. Dr. Pedro Luiz Lima
Bertarini

Coorientador: Prof. Dr. Laurence
Rodrigues Do Amaral

Patos de Minas - MG

2018

HEITOR FERREIRA CAMARGOS SILVA

SISTEMA AUTOMATIZADO DE TOMADA DE DECISÃO EM UM JOGO DE POKER

Trabalho de Conclusão de Curso 2
apresentado à banca examinadora como
pré-requisito para obtenção do título de
bacharel em Engenharia Eletrônica e de
Telecomunicações, na Faculdade de
Engenharia Elétrica, da Universidade
Federal de Uberlândia, Campus Patos de
Minas.

Patos de Minas, 14 de dezembro de 2018

Professor Doutor Pedro Luiz Lima Bertarini (Orientador)
FEELT/UFU

Professor Doutor Laurence Rodrigues do Amaral (Coorientador)
FACOM/UFU

Professor Mestre Bruno Andrade de Souza
FAMAT/UFU

Professor Mestre Alexander Bento Melo
FEELT/UFU

AGRADECIMENTOS

Primeiramente a Deus que permitiu que tudo isso acontecesse, ao longo de minha vida, e não somente nestes anos como universitário, mas que em todos os momentos.

A Universidade Federal de Uberlândia, seu corpo docente, direção e administração que oportunizaram a janela que hoje vislumbro um horizonte superior.

Agradeço a minha mãe Adalgisa Ferreira Silva, heroína que me deu apoio, incentivo nas horas difíceis, de desânimo e cansaço.

Ao meu pai Luis Alberto da Silva, que apesar da distância e de todas as dificuldades me fortaleceu e motivou a chegar até aqui.

Ao meu orientador, Prof. Dr. Pedro Luiz Lima Bertarini, pelo empenho dedicado à elaboração deste trabalho, além da orientação, confiança e apoio durante todo o desenvolvimento.

Ao meu Coorientador, Prof. Dr. Laurence Rodrigues do Amaral pela oportunidade e pelo apoio em todas as etapas de elaboração deste trabalho.

Ao Prof. Ms. Bruno Andrade de Souza e ao Prof. Dr. Jader Conceição da Silva, pela participação na banca e pelo apoio durante o desenvolvimento desse trabalho.

Meus agradecimentos aos amigos que fiz durante a graduação, companheiros de trabalhos e irmãos na amizade que fizeram parte da minha formação e que vão continuar presentes em minha vida com certeza.

RESUMO

O Poker é um esporte com enorme crescimento e destaque no cenário mundial atualmente. Nesse contexto, estão sendo desenvolvidas várias tecnologias relacionadas à área, que já é praticada profissionalmente por milhares de atletas. Também em evidência no século XXI, a mineração de dados e o aprendizado de máquina surgem como excelentes mecanismos para executar tarefas que há alguns anos seriam executadas apenas por humanos, dando às máquinas esse poder. Nesse trabalho, será desenvolvido um mecanismo de tomada de decisões em um jogo de poker com a utilização de algoritmos ligados a subárea da inteligência artificial, de aprendizado de máquina, para tarefas de mineração de dados. A sua implementação contempla vários conceitos de programação e estatística, combinados para conseguir o maior valor esperado (EV – *expected value*) em um jogo de poker na modalidade *No Limit Hold'em - 6 max*, focando nas decisões pré-flop. Durante o trabalho, serão definidas as melhores ações para cada posição da mesa (de um total de seis posições), considerando as possíveis ações anteriores dos oponentes, quantidade de fichas e as cartas recebidas pelo jogador.

Palavras chave: Pôquer. Aprendizado de Máquina. Mineração de Dados. Reconhecimento de Padrões. *Blind. Stack. Algoritmo. Valor Esperado. Range. Flop. Turn. River. Equidade. Conjunto de dados.*

ABSTRACT

Poker is a sport with huge growth and prominence worldwide. In this context, thousands of athletes already practice poker professionally while several technologies related to the area are being developed. Also, in evidence in the twenty-first century, data mining and machine learning emerge as excellent mechanisms for performing tasks that only a few years ago would be performed by humans, giving machines that power. In this work, a decision-making mechanism will be developed in a poker game with the use of algorithms linked to the subarea of artificial intelligence, machine learning, for data mining tasks. Its implementation includes several concepts of programming and statistics, combined to achieve the highest expected value in a No Limit Hold'em - 6 max poker game, focusing on pre-flop decisions. During the work, the best actions for each position of the table (from a total of six positions) will be defined, considering the possible previous actions of the opponents, quantity of chips and the cards received by the player.

Keywords: Poker. Machine Learning. Data Mining. Pattern Recognition. Blind. Stack. Algorithm. Expected value. Range. Flop. Turn. River. Equity. Artificial Intelligence. Dataset.

LISTA DE FIGURAS

Figura 1.1: Resultados do autor em torneios a partir de 2016.....	14
Figura 2.1: Exemplo de carta alta em um <i>ranking</i> de mãos.....	16
Figura 2.2: Exemplo de um par em um <i>ranking</i> de mãos.....	16
Figura 2.3: Exemplo de dois pares em um <i>ranking</i> de mãos.....	16
Figura 2.4: Exemplo de trinca em um <i>ranking</i> de mãos.....	16
Figura 2.5: Exemplo de sequência em um <i>ranking</i> de mãos.....	17
Figura 2.6: Exemplo de <i>flush</i> em um <i>ranking</i> de mãos.....	17
Figura 2.7: Exemplo de <i>full house</i> em um <i>ranking</i> de mãos.....	17
Figura 2.8: Exemplo de quadra em um <i>ranking</i> de mãos.....	17
Figura 2.9: Exemplo de <i>straight flush</i> em um <i>ranking</i> de mãos.....	17
Figura 2.10: Mesa de Poker <i>No Limit Hold'em</i> 6-max.....	20
Figura 2.11: Range com as combinações possíveis em um jogo de poker.....	21
Figura 2.12: Interface gráfica que permite a execução dos algoritmos de mineração de dados do Weka de forma interativa.....	27
Figura 3.1: Construção do <i>dataset</i> no excel.....	26
Figura 3.2: Arquivo .CSV com todas as planilhas unificadas, aberto no bloco de notas.....	34
Figura 3.3: Dados processados no Weka.....	35
Figura 3.4: <i>Training set</i> no Weka <i>Explorer</i>	35
Figura 3.5: <i>Cross-validation</i> no Weka <i>Explorer</i> para n = 10 folds.....	35
Figura 4.1: Funcionamento do PokerBot.....	41
Figura 4.2: Resultado de uma mão que foi decidida pelo <i>PokerBot</i>	42

LISTA DE TABELAS

Tabela 2.1: Probabilidade de realizar determinada mão.....	21
Tabela 2.2: Classificadores disponíveis no Weka e suas funções.....	28
Tabela 4.1: Resultado do <i>training set</i> para todos os classificadores.....	37
Tabela 4.2: Resultado do <i>cross-validation</i> para todos os classificadores com mais de 80% de acertos no <i>training set</i>	38

LISTA DE ABREVIATURAS E SIGLAS

AI Artificial Intelligence	Inteligência Artificial
BB Big Blind	
BTN Button	Botão
CO Cutoff	
EV Expected Value	Valor Esperado
HJ Hijack	
IBL Instance Based Learning	Aprendizagem Baseada em Instâncias
IMSA International Mind Games Association	Associação Internacional de Jogos Mentais
MFS Mathematically Fair Strategy	Estratégia matematicamente justa
NLHE No limit Texas Hold'em	Texas Hold'em Sem Limite
SB Small Blind	
UTG Under The Gun	

SUMÁRIO

CAPÍTULO 1 - INTRODUÇÃO	12
1.1 – OBJETIVOS	13
1.2 – JUSTIFICATIVAS	14
1.3 – CONSIDERAÇÕES	15
CAPÍTULO 2 - REFERENCIAL TEÓRICO	16
2.1 – REVISÃO DE LITERATURA	16
2.1.1 – REGRAS GERAIS DO POKER.....	16
2.1.1.1 – <i>RANKING</i> DE MÃOS.....	17
2.1.1.2 – BLINDS	19
2.1.1.3 – OPÇÕES DE AÇÕES DO JOGADOR	20
2.1.1.4 – PRÉ-FLOP	20
2.1.1.5 – FLOP	20
2.1.1.6 – <i>TURN</i>	20
2.1.1.7 – <i>RIVER</i>	20
2.1.1.8 – SHOW DOWN	21
2.1.2 – <i>NO LIMIT HOLDE’M 6-MAX</i>	21
2.1.3 – COMBOS POSSÍVEIS	22
2.1.4 – ESTRATÉGIAS PRÉ <i>FLOP</i>	23
2.1.4.1 – JOGANDO SHORT STACK (10 a 20bb).....	23
2.1.4.2 – JOGANDO COM STACK MÉDIO (20 a 40bb)	24
2.1.4.2 – JOGANDO DEEP STACK (40bb+)	24
2.1.5 – APRENDIZADO DE MÁQUINA.....	24
2.1.6 – MINERAÇÃO DE DADOS.....	25
2.1.6.1 – TAREFAS.....	26
2.1.7 – WEKA EXPLORER.....	27
2.1.7.1 – CLASSIFICADORES	28
2.1.7.2 – AVALIAÇÃO DO APRENDIZADO	30

2.1.7.2.1 – TREINAMENTO E TESTE	30
2.1.7.2.2 – VALIDAÇÃO CRUZADA	30
2.1.8 – JOGADORES ARTIFICIAIS EXISTENTES	30
2.1.8.1 – JOGADORES ARTIFICIAIS ESTÁTICOS.....	31
2.1.8.2 – JOGADORES ARTIFICIAIS EVOLUTIVOS	31
2.1.8.2.1 – APRENDIZADO POR REFORÇO	32
2.2 – CONSIDERAÇÕES FINAIS.....	32
CAPÍTULO 3 - METODOLOGIA.....	33
3.1 – CRIAÇÃO DE UMA BASE DE DADOS COM AS POSSÍVEIS AÇÕES	33
3.2 – ADAPTAÇÃO DA BASE DE DADOS PARA SER PROCESSADA	34
3.3 – TREINAMENTO E VALIDAÇÃO CRUZADA DOS DADOS.....	35
3.4 – PROGRAMAÇÃO.....	37
CAPÍTULO 4 – RESULTADOS E DISCUSSÕES	38
CAPÍTULO 5 – CONCLUSÕES, CONTRIBUIÇÕES DESTE TRABALHO E TRABALHOS FUTUROS	43
GLOSSÁRIO	44
REFERÊNCIAS	46

CAPÍTULO 1 - INTRODUÇÃO

Poker é um jogo de cartas que foi reconhecido em 2010 como esporte da mente pela *International Mind Games Association* (IMSA) e o colocou na mesma categoria de outros esportes da mente como xadrez, bridge, dama e go [1]. O poker pode ser praticado de dois a dez jogadores que participam das rodadas de apostas em dinheiro (real ou fictício), vencendo aquele que tiver a combinação mais forte conforme a hierarquia das cartas ou fazendo os adversários desistirem da jogada. O poker possui diversas modalidades, sendo mais popular o Texas *Hold'em* [2].

A beleza do poker é que superficialmente ele é um jogo simples. Qualquer um pode aprender as regras em poucos minutos. Para os jogadores experientes, essa simplicidade, que ilude muitos jogadores a pensarem que são bons, é o que faz a lucratividade do poker. No longo prazo todos têm a mesma proporção e porcentagem de receber boas ou más cartas e mãos vencedoras ou perdedoras. Os jogadores profissionais usam suas habilidades para minimizar a sorte, reduzindo as perdas nas piores mãos e maximizando os ganhos nas melhores mãos [3].

Nesse contexto, este trabalho aplicará técnicas e conceitos de *Machine Learning* e *Data Mining*, que podem ser consideradas subárea da Inteligência Artificial (*AI - Artificial Intelligence*), para tomar as melhores decisões *pré-flop* em um jogo de poker. AI é a teoria e desenvolvimento de sistemas de computadores capazes de executar tarefas que normalmente exigem inteligência humana, como a percepção visual, reconhecimento de voz, tomada de decisão e tradução entre idiomas, por exemplo [4].

Esse trabalho utiliza algoritmos inteligentes para tomar as melhores decisões em um jogo de poker, na modalidade *No Limit Texas Hold'em (NLHE) 6-max*, quando no máximo 6 jogadores podem jogar em cada mesa simultaneamente, com foco nas ações *pré-flop* (antes de virar as três primeiras cartas), em três faixas de *stack* (quantidade de fichas por jogador). Durante o processo de tomada de decisão, vários fatores importam: (i) a força da mão, (ii) a posição da mesa que está, (iii) quantidade de fichas e (iv) quais as ações anteriores dos seus oponentes, dentre outras.

Assim, a árvore de decisões para a melhor jogada se torna bastante complexa pelo fato de ter que prever as possíveis ações de cada adversário e, a partir dessas ações, apontar a jogada com mais *Expected Value (EV)*, que é o que o jogador perde ou

ganha em média considerando todos os resultados possíveis e as suas probabilidades. Por exemplo, se um jogador está na posição *Big Blind* (BB), que será a última a ter ação na mesa, ele dependerá das possíveis decisões de cinco oponentes antes de tomar sua decisão.

A teoria do jogo de poker parte da hipótese que toda vez que um determinado jogador joga uma mão diferentemente da maneira que jogaria caso pudesse ver as cartas de seus oponentes, eles ganham. E toda vez que esse jogador joga sua mão do mesmo jeito que teria jogado caso pudesse ver todas as cartas de seus oponentes, eles perdem [3]. Ou seja, se esse determinado jogador tivesse a informação completa no poker, ele sempre venceria. Por outro lado, caso o adversário também tivesse a informação completa, ele venceria. A melhor forma de vencer, portanto, é tentar obter informação completa e dificultar ao máximo o adversário de obter essa informação [6].

Para isso, serão montadas faixas de decisões para cada posição da mesa, baseados nas jogadas +EV a longo prazo, tentando maximizar os ganhos do jogador inteligente, tomando a melhor decisão *pré-flop*, com três ações principais:

- 1 – *fold*: desistir de jogar a mão *pré-flop*;
- 2 – *call*: pagar a aposta mínima ou a aposta de um oponente feita antes de chegar à sua vez;
- 3 – *raise*: aumentar a aposta anterior [5].

Com uma boa amostragem de mãos jogadas pelo jogador inteligente, a taxa de ganhos *pré-flop* será positiva, levando em consideração que os *ranges* foram construídos para maximizar o EV em cada jogada, analisando todos os cenários possíveis e não apenas tomando uma decisão aleatória.

1.1 – OBJETIVOS

Esse trabalho tem o objetivo de desenvolver um jogador inteligente de poker para tomar as melhores decisões *pré-flop* com a utilização de classificadores e algoritmos de aprendizado de máquina. São objetivos gerais deste trabalho:


- Desenvolver um trabalho de conclusão de curso, relacionando o poker ao curso de Engenharia Eletrônica e de Telecomunicações;

- Utilizar classificadores e algoritmos de aprendizado de máquina para a melhor tomada de decisão em um jogo de poker.
- Desenvolver um programa para a melhor tomada de decisões a partir de uma árvore de decisões baseada em *ranges* matemáticos, que possa ser lucrativo a longo prazo em um jogo de poker;
- Maximizar acertos e minimizar erros *pré-flop* cometidos por um jogador inteligente de poker.

1.2 – JUSTIFICATIVAS

O Poker é um dos esportes com maior crescimento na atualidade, sendo praticado por milhões de pessoas por todo o mundo. Atualmente, existem alguns jogadores brasileiros em destaque no cenário mundial, que já ultrapassam a casa dos milhões de dólares em lucro, entre poker online e ao vivo. Entre os principais, estão nomes como de João Simão, Rafael Moraes e Bernardo Dias. Além disso, o poker é praticado profissionalmente pelo autor deste trabalho desde 2016, com os resultados do início da carreira (2016) até hoje mostrados na Figura 1.1. Pode-se perceber uma curva crescente de lucratividade, quando os principais resultados são destacados por curvas acentuadas e pelo símbolo \$.

Figura 1.1: Resultados do autor em torneios a partir de 2016.



Fonte: [6].

Surge daí o interesse de desenvolver um trabalho, que relacione o poker, com a Engenharia Eletrônica e de Telecomunicações, visando a criação de um sistema automatizado para tomada de decisão.

1.3 – CONSIDERAÇÕES

Tanto o poker quanto o aprendizado de máquina estão em crescimento nos últimos anos. Com esse trabalho de conclusão de curso, será possível relacionar as duas áreas e desenvolver um programa que poderá ajudar iniciantes e até mesmo jogadores experientes minimizar erros e maximizar acertos em um jogo de poker.

Assim, este trabalho está dividido da seguinte forma: no capítulo 2 é apresentado um referencial teórico, explicando os conceitos que serão úteis no desenvolvimento do trabalho. No capítulo 3, por sua vez, são apresentados os materiais e a metodologia utilizada para desenvolver o trabalho, seguido de resultados e discussões no capítulo 4 e das considerações finais, contribuições e projetos futuros relacionados ao trabalho no capítulo 5.

CAPÍTULO 2 - REFERENCIAL TEÓRICO

Jogar é uma das áreas de trabalho/esforço do aprendizado de máquina. Em 1950, logo após os computadores se tornarem programáveis, o primeiro programa de xadrez foi escrito por Claude Shannon (o inventor da teoria da informação) e por Alan Turing. Desde então, tem ocorrido um sólido progresso nos padrões de jogar, ao ponto em que os sistemas atuais podem desafiar campeões mundiais humanos sem medo de constrangimento [9].

A complexidade dos jogos introduz um tipo de incerteza completamente novo que não vimos ainda: a incerteza acontece não por falta de informação, mas porque não há tempo de calcular a exata consequência de qualquer movimento. Ao invés disso, alguém deve fazer a melhor tentativa baseado em experiência passada, e agir antes de ter certeza de qual ação tomar [9].

Partindo do princípio descrito acima, os jogos se tornam um grande estímulo na subárea de inteligência artificial para descobrir novas soluções para problemas que podem ser generalizados e aplicados para resolver situações diárias, já que os problemas do cotidiano apresentam semelhança com os desafios criados em determinados jogos. Decidir o preço de um produto é um exemplo de um problema que poderia ser resolvido através de uma solução semelhante à solução do Poker, pois ambos precisam tomar decisões que podem ser rentáveis ou não e ambos contêm informações incompletas [7].

2.1 – REVISÃO DE LITERATURA

Esta seção mostrará o embasamento teórico desse trabalho, desde as regras gerais do poker até as técnicas de aprendizado de máquina, mineração de dados e reconhecimento de padrão utilizadas no seu desenvolvimento.

2.1.1 – REGRAS GERAIS DO POKER

No *Texas Hold'em* (modalidade de poker utilizada para desenvolver o trabalho), cada jogador recebe duas cartas próprias, de um baralho com cinquenta e duas cartas, que pertencem somente a ele. Cinco cartas comunitárias são distribuídas viradas para cima, para formar o bordo. Todos os jogadores no jogo utilizam essas cartas comunitárias compartilhadas em conjunto com suas cartas próprias para formar sua melhor mão de poker de cinco cartas possível. Assim, um jogador pode utilizar


qualquer combinação de sete cartas disponível para fazer a melhor mão de poker possível com cinco cartas, utilizando nenhuma, uma ou duas de suas *cartas* [10].

2.1.1.1 – RANKING DE MÃOS

O *ranking* é o valor de um conjunto de cinco cartas. Quase todos os *Ranking* dependem da “maior carta”. A ordem das cartas são, em ordem decrescente: A, K, Q, J, 10, 9, 8, 7, 6, 5, 4, 3, 2 [5]. Abaixo, é mostrado o *ranking* em ordem crescente:

- I. Carta alta (*High Cards*): Cinco cartas diferentes. A maior carta vence.

Figura 2.1: Exemplo de carta alta em um *ranking* de mãos.



Fonte: [13].

- II. Um par (*One Pair*): Par são duas cartas com o mesmo número e três cartas diferentes.

Figura 2.2: Exemplo de um par em um *ranking* de mãos.



Fonte: [13].

- III. Dois pares (*Two Pairs*): Dois pares e uma carta diferente.

Figura 2.3: Exemplo de dois pares em um *ranking* de mãos.



Fonte: [13].

- IV. Trinca (*Three Of A Kind*): Trinca são três cartas com o mesmo número e duas cartas diferentes.


Figura 2.4: Exemplo de trinca em um *ranking* de mãos.



Fonte: [13].

- V. Sequência (*Straight*): Sequência são cinco cartas na sequência de número.


Figura 2.5: Exemplo de sequência em um *ranking* de mãos.



Fonte: [13].

- VI. Naipes iguais (*Flush*): Cinco cartas diferentes com naipes iguais.


Figura 2.6: Exemplo de *flush* em um *ranking* de mãos.



Fonte: [13].

- VII. Trinca e par (*Full House*): Três cartas com o mesmo número e duas com o mesmo número.

Figura 2.7: Exemplo de *full house* em um *ranking* de mãos.



Fonte: [13].

- VIII. Quadra (*Four Of A Kind*): Quatro cartas com o mesmo número e uma carta diferente.


Figura 2.8: Exemplo de quadra em um *ranking* de mãos.



Fonte: [13].

- IX. Sequência com naipes iguais (*Straight Flush*): O maior *ranking* do poker. Cinco cartas em sequência com o mesmo naipe.

Figura 2.9: Exemplo de *straight flush* em um *ranking* de mãos.



Fonte: [13]

Com a utilização de todas as combinações, é mostrado na Tabela 2.1 a chance de realizar cada mão presente no *ranking* mostrado anteriormente.

Tabela 2.1: Probabilidade de realizar determinada mão.

Mão	Mãos diferentes	Frequência	Probabilidade	Probabilidade Cumulativa	Odds	Expressão Matemática de frequência absoluta
Straight Flush	9	36	0,00139%	0,0015%	72.192: 1	$\binom{10}{1}\binom{4}{1} - \binom{4}{1}$
Quadra	156	624	0,0240%	0,0256%	4,164: 1	$\binom{13}{1}\binom{12}{1}\binom{4}{1}$
Full House	156	3,744	0,1441%	0,17%	693: 1	$\binom{13}{1}\binom{4}{3}\binom{12}{1}\binom{4}{2}$
Flush	1,277	5,108	0,1965%	0,367%	508: 1	$\binom{13}{5}\binom{4}{1} - \binom{10}{1}\binom{4}{1}$
Sequência	10	10.200	0,3925%	0,76%	254: 1	$\binom{10}{1}\binom{4}{1}^5 - \binom{10}{1}\binom{4}{1}$
Trinca	858	54,912	2,1128%	2,87%	46.3: 1	$\binom{13}{1}\binom{4}{3}\binom{12}{2}\binom{4}{1}^2$
Dois pares	858	123,552	4,7539%	7,62%	20.0: 1	$\binom{13}{2}\binom{4}{2}^2\binom{11}{1}\binom{4}{1}$
Um par	2,860	1.098.240	42,2569%	49,9%	1,37: 1	$\binom{13}{1}\binom{4}{2}\binom{12}{3}\binom{4}{1}^3$
Carta alta	1,277	1,302,540	50.1177%	100%	0,995: 1	$[(\binom{13}{5} - 10)][(\binom{4}{1}^5 - 4)]$

Fonte: Elaborada pelo autor.

2.1.1.2 – BLINDS

No *Hold'em*, um marcador chamado "botão" indica qual jogador é o *dealer* designado para a mão atual. Antes da mão começar, o jogador imediatamente a esquerda do botão coloca o *small blind (SB)*, a primeira aposta obrigatória. O jogador imediatamente a esquerda do *SB* coloca o *BB*, que geralmente é duas vezes o tamanho do *SB*. Os *blinds* podem variar dependendo dos valores e da estrutura de apostas em jogo. Nos jogos *No Limit*, foco desse projeto, os jogos são denominados pelo tamanho dos blinds (por exemplo, um jogo \$ 1 / \$ 2 de *Hold'em* tem o *SB* de US\$ 1 e o *BB* de US\$ 2) [10].

Após cada jogador receber suas cartas próprias, a ação acontece no sentido horário na mesa, com início no jogador *Under The Gun* (UTG), imediatamente a esquerda do *BB*, seguido de Hijack (HJ), *Cutoff* (CO) e *Button* (BTN).

2.1.1.3 – OPÇÕES DE AÇÕES DO JOGADOR

Na modalidade *Hold'em*, assim como em muitos formatos de poker, as ações disponíveis são *fold* (descartar), *check* (passar), *bet* (apostar), *call* (pagar) ou *raise* (aumentar). As opções disponíveis dependem da ação tomada pelos jogadores anteriores. Se ninguém ainda tiver feito uma aposta, então o jogador pode dar *check* (passar a vez sem apostar, mas mantendo as cartas) ou *bet* (apostar). Se um jogador tiver apostado, os jogadores subsequentes podem dar *fold*, *call* ou *raise* [10].

2.1.1.4 – PRÉ-FLOP

Quando todos os jogadores da mesa recebem suas duas cartas e são postados o *SB* e o *BB*, cada jogador, decide entre *fold*, *call* ou *raise* baseado apenas na força das suas duas cartas, na posição e nas ações anteriores dos outros jogadores, sem saber o que irá virar nas cinco cartas voluntárias.

2.1.1.5 – FLOP

As três primeiras cartas voluntárias são distribuídas abertas no bordo, disponíveis para todos os jogadores ainda na mão. Isso é conhecido como *flop*. As apostas no *flop* começam com o jogador ativo imediatamente a esquerda do botão. As opções de aposta são similares ao *pré-flop*, no entanto se não houver apostas anteriores, os jogadores podem optar por dar *check*, passando a vez para o próximo jogador ativo no sentido horário [10].

2.1.1.6 – TURN

O *turn* é a quarta carta comunitária no *Hold'em* e é virada quando a rodada de apostas no *flop* é encerrada e mais de um jogador continua na mão. Outra rodada de apostas se inicia, começando com o jogador ativo imediatamente a esquerda do botão.

2.1.1.7 – RIVER

O *river* é a quinta e última carta comunitária em um jogo de *Hold'em* e é virada quando a rodada de apostas no *turn* é encerrada e mais de um jogador continua na

mão. A ação nas apostas começa com o jogador ativo imediatamente a esquerda do botão, e as mesmas regras de apostas do *flop* e do *turn* se aplicam.

2.1.1.8 – SHOW DOWN

Se existir mais do que um jogador restando quando a rodada final de apostas estiver completa, a última pessoa a apostar ou dar *raise* mostra suas cartas, a menos que não existam apostas na rodada final. Nesse caso, o jogador imediatamente a esquerda do botão mostra suas cartas primeiro. O jogador com a melhor mão de poker de cinco cartas ganha o pote. No caso de mãos idênticas, o pote será igualmente dividido entre os jogadores com as melhores mãos. Depois do pote ser concedido aos vencedores, uma nova mão de *Hold'em* está pronta para ser jogada. O botão agora se move no sentido horário para outro jogador, os *blinds* são novamente colocados, e novas mãos são distribuídas para cada jogador [10].

2.1.2 – NO LIMIT HOLDE’M 6-MAX

Em um jogo *No Limit Hold'em* a aposta mínima é igual ao tamanho do *Big Blind*, mas os jogadores sempre podem apostar a quantidade que desejarem, até o total de suas fichas, daí a expressão “*No Limit*”. Dentre todas as modalidades de apostas no poker, atualmente a *No Limit* é a mais popular, provavelmente pela simplicidade de executar uma aposta.

Já o termo *6-max*, faz referência a quantidade de jogadores permitida em uma mesa. Numa mesa com no máximo seis jogadores, a dinâmica do jogo muda bastante em relação ao *Full Ring* (termo utilizado para mesa com nove jogadores), pois são três posições a menos em jogo. Isso significa que mais vezes o jogador vai estar em posição final na mesa e certamente a frequência que ele irá jogar irá aumentar.

Utilizando a *Data Base* (o histórico de mãos jogadas) de um jogador regular de poker online para demonstrar essa diferença, com uma amostragem de 322 mil mãos jogadas, nota-se que em média de todas as posições o jogador no *Full Ring* joga 23,95% das mãos, enquanto no *6-max* o mesmo jogador joga 30,94% das mãos. É uma diferença de aproximadamente 7% e que será muito relevante para estabelecer o *range* adequado para o jogador inteligente do projeto. Para a coleta de dados, foi utilizado o *software* de mineração de dados PokerTracker [12]. A Figura 2.10 mostra como é formada uma mesa *6-max*:

Figura 2.10: Mesa de Poker *No Limit Holde'm* 6-max.

Fonte: Adaptado de [12].

2.1.3 – COMBOS POSSÍVEIS

Em um baralho de 52 cartas, é possível diversas combinações de duas cartas, como mostrado na Fórmula 1:

$$\frac{n!}{k!(n-k)!} = \binom{n}{k} = \binom{52}{2} = 1326 \quad (1)$$

As 1326 combinações possíveis, consideram os quatro naipes do baralho. Nesse trabalho, será mais relevante saber se a combinação é *suited* (do mesmo naipe) ou *off suited* (de naipes diferentes), pois como o foco é pré-*flop*, não vai ser relevante saber se determinado jogo *suited* é de paus, copas, espadas ou ouros antes de ver o *flop*, e sim a força da mão pré-*flop* para executar a melhor ação.

Ao focar nas mãos *suited* e *off suited*, a combinação reduz a 169 mãos iniciais possíveis, sendo 13 pares, 78 combinações *suited* e 78 combinações *off suited*. A frequência com que cada combinação de cartas vai ser jogada, vai depender da força da mão, da posição e das ações anteriores, principalmente. A Figura 2.11, mostra as 169 combinações possíveis.

Figura 2.11: Range com as combinações possíveis em um jogo de poker.

AA	AKs	AQs	AJs	ATs	A9s	A8s	A7s	A6s	A5s	A4s	A3s	A2s
AKo	KK	KQs	KJs	KTs	K9s	K8s	K7s	K6s	K5s	K4s	K3s	K2s
AQo	KQo	QQ	QJs	QTs	Q9s	Q8s	Q7s	Q6s	Q5s	Q4s	Q3s	Q2s
AJo	KJo	QJo	JJ	JTs	J9s	J8s	J7s	J6s	J5s	J4s	J3s	J2s
ATo	KTo	QTo	JTo	TT	T9s	T8s	T7s	T6s	T5s	T4s	T3s	T2s
A9o	K9o	Q9o	J9o	T9o	99	98s	97s	96s	95s	94s	93s	92s
A8o	K8o	Q8o	J8o	T8o	98o	88	87s	86s	85s	84s	83s	82s
A7o	K7o	Q7o	J7o	T7o	97o	87o	77	76s	75s	74s	73s	72s
A6o	K6o	Q6o	J6o	T6o	96o	86o	76o	66	65s	64s	63s	62s
A5o	K5o	Q5o	J5o	T5o	95o	85o	75o	65o	55	54s	53s	52s
A4o	K4o	Q4o	J4o	T4o	94o	84o	74o	64o	45o	44	43s	42s
A3o	K3o	Q3o	J3o	T3o	93o	83o	73o	63o	35o	43o	33	32s
A2o	K2o	Q2o	J2o	T2o	92o	82o	72o	62o	25o	42o	23o	22

Fonte: Elaborada pelo autor.

As combinações em verde, são as melhores mãos, que tendem a jogar numa frequência maior que as demais. Já em azul, são as mãos com equidade (probabilidade de ganhar) mediana e em branco as mãos que só vão jogar em posições finais e com uma frequência reduzida. Vale ressaltar que as combinações com 's' a frente é do mesmo naipe (*suited*) e com 'o' a frente de naipes diferentes (*off suited*).

2.1.4 – ESTRATÉGIAS PRÉ FLOP

O jogo pré-*flop* ainda é a base do jogo de todos os grandes jogadores. Caso não haja um bom jogo pré-*flop*, é muito improvável que seja um jogador vencedor, independente de quão boas sejam suas habilidades pós-*flop* [11].

2.1.4.1 – JOGANDO SHORT STACK (10 a 20bb)

Todas as decisões que um jogador toma enquanto é *short stack* (quantidade pequena de *blind*) pré-*flop* valem uma grande parte do seu *stack* total, então usar estratégias de *open* e de *3-bet-shove* (aumentar a aposta para todas as fichas) é fundamental para o lucro a longo prazo.

É importante ter ciência do tamanho efetivo do próprio *stack* e do *stack* dos oponentes que estão na mesa, para que seja possível construir uma boa estratégia. É necessário, ainda, considerar a jogabilidade pós *flop* de determinada mão. Quando o jogador está com um *short stack* com uma mão que vai jogar mal no pós-*flop*, mas provavelmente é a melhor mão pré-*flop*, o *all in* pode ser a ação mais apropriada. Isso deve evitar decisões difíceis no pós-*flop*. Exemplo de mãos do tipo são pequenos pares (22 a 55) [14].

2.1.4.2 – JOGANDO COM STACK MÉDIO (20 a 40bb)

Nessa situação, tem-se um *stack* um pouco mais confortável para trabalhar. Não se pode realizar todo tipo de ação, mas já tem espaço para uma maior jogabilidade. Com esse *stack* pode-se dar mais *raise* em posição e jogar de *call* com parte do *range* e ver alguns *flops*, além de ter espaço para dar alguns 3-*bet* ou 4-*bet light* (reaumentar a aposta do(s) adversário(s) por blefe) [15].

2.1.4.2 – JOGANDO DEEP STACK (40bb+)

Nessa faixa de *stack*, é bem confortável de se jogar. Podendo variar o estilo de jogo conforme reagem os oponentes. Vale dar preferência em jogar mãos com equidade robusta, ou seja, que jogam bem pós-*flop* e possibilita extrair muitas fichas dos adversários quando fizer a melhor mão. Exemplo de mãos com equidade robusta são os “*suited conector*”, mãos conectadas e do mesmo naipe, como 78s ou JTs.

2.1.5 – APRENDIZADO DE MÁQUINA

O aprendizado está diretamente ligado com a inteligência, pois realmente se um sistema é capaz de aprender a exercer determinada tarefa mereça então ser chamado de inteligente. Assim é possível afirmar que o aprendizado de máquina nada mais é um aprendizado por experiência, que conforme a tarefa é executada, o problema aprende a melhor maneira de resolver. Além de estruturar o conhecimento existente, para levar a um entendimento do aprendizado [16].

Existem diversos métodos de aprendizado de máquina. Entre eles o aprendizado por hábito, que tem como característica o programa aprender por experiência de acordo com o que foi informado anteriormente. Há também o método de aprendizado por conceito, que analisa todas as hipóteses e demonstra qual é a correta. No método do conceito existe uma subdivisão, que é a “hipótese mais geral”,

o que significa que se não existe nenhuma possibilidade correta, o programa achará a que mais se aproxima do correto [17].

Atualmente, uma forma avançada de aprendizado de máquina são as redes neurais, que se assemelham com o funcionamento do cérebro humano, sendo uma grande rede de neurônios. Essa rede é organizada geralmente em duas camadas. A primeira recebe as informações a serem classificadas e usa aprendizado supervisionado por modificarem a forma das conexões de acordo com o que é informado para, por último, ativar os neurônios de saída. É uma forma bastante complexa, mas tem muita utilidade por ser bastante precisa e dificilmente acontecer erros, que em outros ambientes de aprendizagem são comuns [17].

Os algoritmos de *Machine Learning* podem ser divididos em 3 categorias: aprendizagem supervisionada, aprendizagem não supervisionada e aprendizado por reforço. A aprendizagem supervisionada é útil nos casos em que uma propriedade está disponível para um determinado conjunto de dados. O aprendizado não supervisionado é útil nos casos em que o desafio é descobrir relacionamentos implícitos em um dado conjunto de dados não-rotulado (os itens não são pré-atribuídos). O aprendizado de reforço está entre estes dois extremos [19].

2.1.6 – MINERAÇÃO DE DADOS

Por ser considerada multidisciplinar, as definições acerca do termo Mineração de Dados variam com o campo de atuação dos autores. Existem três áreas que são consideradas como de maior expressão dentro da Mineração de Dados: Estatística, Aprendizado de Máquina e Banco de Dados [21].

- Estatística: Mineração de Dados é a análise de grandes conjuntos de dados a fim de encontrar relacionamentos inesperados e de resumir os dados de uma forma que eles sejam tanto úteis quanto compreensíveis ao dono dos dados [22].
- Banco de dados: Mineração de Dados é um campo interdisciplinar que junta técnicas de máquinas de conhecimentos, reconhecimento de padrões, estatísticas, banco de dados e visualização, para conseguir extrair informações de grandes bases de dados [23].
- Aprendizado de Máquina: Mineração de Dados é um passo no processo de Descoberta de Conhecimento que consiste na realização da análise dos dados

e na aplicação de algoritmos de descoberta que, sob certas limitações computacionais, produzem um conjunto de padrões de certos dados [24].

Apesar de encontrarmos diversas ferramentas que nos auxiliam na execução dos algoritmos de mineração, os resultados ainda precisam de uma análise humana. Porém, ainda assim, a mineração contribui de forma significativa no processo de descoberta de conhecimento, permitindo aos especialistas concentrarem esforços apenas em partes mais significativa dos dados [21].

2.1.6.1 – TAREFAS


A Mineração de Dados é comumente classificada pela sua capacidade em realizar determinadas tarefas [25]. As tarefas mais comuns são:

- **Descrição:** é a tarefa utilizada para descrever os padrões e tendências revelados pelos dados. A descrição geralmente oferece uma possível interpretação para os resultados obtidos.
- **Classificação:** uma das tarefas mais comuns, a Classificação, visa identificar a qual classe um determinado registro pertence. Nesta tarefa, o modelo analisa o conjunto de registros fornecidos, com cada registro já contendo a indicação à qual classe pertence, a fim de ‘aprender’ como classificar um novo registro (aprendizado supervisionado).
- **Estimação ou Regressão:** a estimação é similar à classificação, porém é usada quando o registro é identificado por um valor numérico e não um categórico. Assim, pode-se estimar o valor de uma determinada variável analisando-se os valores das demais.
- **Predição:** a tarefa de predição é similar às tarefas de classificação e estimação, porém ela visa descobrir o valor futuro de um determinado atributo.
- **Agrupamento:** a tarefa de agrupamento visa identificar e aproximar os registros similares. Um agrupamento é uma coleção de registros similares entre si, porém diferentes dos outros registros nos demais agrupamentos.
- **Associação:** a tarefa de associação consiste em identificar quais atributos estão relacionados. Apresentam a forma: SE atributo X ENTÃO atributo Y [21].

2.1.7 – WEKA EXPLORER

O pacote de *software* Weka é um conjunto de algoritmos, ligados a subárea da inteligência artificial, de aprendizado de máquina, para tarefas de mineração de dados. Ele contém ferramentas para preparação de dados, classificação, regressão, agrupamento, mineração de regras de associação e visualização. A Figura 2.12 mostra a interface gráfica do *Weka*:

Figura 2.12: Interface gráfica que permite a execução dos algoritmos de mineração de dados do Weka de forma interativa.



Fonte: [26].

No desenvolvimento do trabalho, as partes mais utilizadas foram a de preparação de dados, que escolhe e modifica os dados utilizados e a de classificação, que treina e testa sistemas de aprendizagem que classificam ou realizam regressão do *dataset*.

2.1.7.1 – CLASSIFICADORES

Estão disponíveis no *Weka* 43 algoritmos classificadores, divididos em 7 famílias, de acordo com suas semelhanças e funções. Todos algoritmos, com suas respectivas famílias e funções, são mostrados na Tabela 2.2.

Tabela 2.2: Classificadores disponíveis no *Weka* com suas funções.

Família	Nome	Função
BAYES	BayesNet	Aprende redes Bayesianas
	NaiveBayes	Classificador probabilístico padrão Naïve Bayes
	NaiveBayesMultinomial	Multinomial versão de Naïve Bayes
	NaiveBayesUpdateable	Classificador Naïve Bayes multinomial incremental que aprende uma instância de cada vez
FUNCTIONS	Logistic	Constrói modelos de regressão logística linear
	MultilayerPerception	Rede neural de retro propagação
	SimpleLogistic	Cria modelos de regressão logística linear com seleção de atributos incorporados
	SMO	Algoritmo de otimização mínima sequencial para classificação de vetores de suporte
LAZY	IBK	Aprendizado baseado em instâncias do vizinho mais próximo
	KStar	Classificador de k vizinhos mais próximos
	LWL	Algoritmo geral para aprendizagem ponderada localmente
RULES	DecisionTable	Cria um classificador de tabela de decisão simples
	JRip	Algoritmo Ripper para indução rápida e eficaz de regras
	OneR	Classificador 1R
	PART	Obtém regras de árvores de decisão parciais construídas usando J48
	ZeroR	Aprendiz da regra de Ripper
TREES	DecisionStump	Constrói árvores de decisão de um nível
	HoeffdingTree	É um algoritmo de indução de árvore de decisão incremental
	J48	Aprendiz de árvore de decisão
	LMT	Constrói árvores de modelo logístico
	RandomForest	Constrói um conjunto de árvores aleatórias
	RandomTree	Constrói uma árvore que considera um determinado número de recursos aleatórios em cada nó

	REPTree	Aprendiz de árvore de decisão rápida
MISC	InputMappedClassifier	Cria um mapeamento entre os dados de treinamento
	SerializedClassifier	Um embrulho em torno de um modelo de classificador
META	AdaBoostM1	Classe para impulsionar um classificador de classe nominal usando o método Adaboost M1
	AttributeSelectedClassifier	A dimensão dos dados de treinamento e teste é reduzida
	Bagging	Classe para guardar um classificador para reduzir a variação
	ClassificationViaRegression	Classe para fazer classificação usando métodos de regressão
	CostSensitiveClassifier	Um metaclassificador que torna seu classificador de base sensível ao custo
	CVParameterSelection	Classe para executar a seleção de parâmetros por validação cruzada para qualquer classificador
	FilteredClassifier	Classe para executar um classificador arbitrário em dados que foram passados por um filtro arbitrário
	IterativeClassifierOptimizer	Otimiza o número de iterações do classificador iterativo fornecido usando validação cruzada
	LogitBoost	Classe para executar a regressão logística aditiva
	MultiClassClassifier	Um metaclassificador para lidar com conjuntos de dados de várias classes com classificadores de duas classes
	MultiClassifierUpdatable	Um metaclassificador para lidar com conjuntos de dados de várias classes com classificadores de duas classes
	MultiScheme	Classe para selecionar um classificador entre vários usando validação cruzada
	RandomCommittee	Classe para construir um conjunto de classificadores de base aleatórios
	RandomizableClassifier	Utiliza RandomProjection e IBk como os classificadores base
	RandomSubSpace	Constrói um classificador baseado em árvore de decisão que mantém a mais alta precisão nos dados de treinamento
	Stacking	Combina vários classificadores usando o método de empilhamento
	Vote	Classe para combinar classificadores

	WeightedInstanceWrapper	Embrulho genérico em torno de qualquer classificador para permitir o suporte a instâncias
--	-------------------------	---

Fonte: Adaptado de [28].

2.1.7.2 – AVALIAÇÃO DO APRENDIZADO

A avaliação é um processo fundamental na mineração de dados. Para cada problema particular, é preciso avaliar de maneira sistemática como cada algoritmo funciona e comparar com os outros, até encontrar o que melhor se adeque a situação. No *Weka* existem diversos tipos de avaliadores. Dois modelos foram utilizados e comparados nesse trabalho, e são detalhados a seguir.

2.1.7.2.1 – TREINAMENTO E TESTE

Para problemas de classificação, geralmente é medido o desempenho de um classificador em termos da taxa de erro. O classificador prevê a classe de cada instância: se for correto, isso é contado como um sucesso, se não, é um erro. A taxa de erro é apenas a proporção de erros cometidos ao longo de todo um conjunto de instâncias e mede o desempenho do classificador [28]. Nesse método de avaliação, quanto maior a base de dados e quanto mais for treinado, mais confiáveis se tornam os resultados da avaliação.

2.1.7.2.2 – VALIDAÇÃO CRUZADA

Este método consiste em pegar um conjunto de dados de tamanho N e dividir em M subconjuntos de tamanho N/M . Em seguida, o algoritmo é treinado M vezes, cada vez com um subconjunto diferente sendo deixado de fora para fazer a validação. O desempenho da validação cruzada é medido como sendo a taxa de acerto média sobre os M subconjuntos de validação. Esse método é chamado também de *Leave-one-out*.

2.1.8 – JOGADORES ARTIFICIAIS EXISTENTES

Existem diversos modelos de jogadores artificiais atualmente. A tendência é que cada vez mais esses jogadores consigam um nível de jogo igual ou superior ao dos humanos. Alguns exemplos se destacam: os Jogadores Artificiais Estáticos e os Jogadores Artificiais Evolutivos.

2.1.8.1 – JOGADORES ARTIFICIAIS ESTÁTICOS

Jogadores artificiais estáticos são jogadores que tomam decisões baseado em uma função imutável. Aqui são citados quatro exemplos: aleatórios, constantes, MFS e RH.

O jogador aleatório despreza as principais variáveis do jogo e joga aleatoriamente. Pode-se dizer que é o modelo mais simplista de todos. Os jogadores constantes, por sua vez, sempre tomam a mesma decisão, desprezando também as principais variáveis do jogo, o que o torne simples.

Já o MFS (*Mathematically Fair Strategy*) é um tipo de jogador que joga justo em relação a probabilidade de vencer. Ele aposta proporcional a probabilidade e ao pote. A relação MFS é obtido por V pela fórmula:

$$V = (A * W) - (L * J) \quad (2)$$

Onde W é a probabilidade de o jogador vencer, L é a probabilidade de o jogador perder, A é a soma de aposta feita pelos adversários e J é a soma de aposta feita pelo jogador [15].

Por fim, o jogador RH. Esse tipo de jogador foi gerado a partir de um estudo estatístico de dois estudantes: Jean Rachlin e Gary Higgins. Eles chegaram à conclusão que na maioria dos jogos, a chance de um jogador vencer depende de um conjunto de variáveis e não apenas das cartas em suas mãos, algumas diretamente proporcionais e outras inversamente proporcionais. Eles chegaram na seguinte equação:

$$V = \frac{P}{(C+1)*L*F*R} \quad (3)$$

Onde P é o pote, R é o raise, L é a quantidade de jogadores que estão no jogo, F é a quantidade de jogadores que precisam tomar alguma decisão antes de acabar a rodada e C é a quantidade de vezes que alguém decidiu dar *raise* [16].

2.1.8.2 – JOGADORES ARTIFICIAIS EVOLUTIVOS

Ao contrário de jogadores estáticos, esses jogadores aprendem com a experiência. A função de decisão é mutável de acordo com um banco de dados de experiência. Essa experiência pode ter informações sobre um jogador específico, que

é uma boa estratégia partindo da hipótese de que jogadores de poker tendem a jogar da mesma maneira. O banco pode ter também informações sobre situações de jogos em que o jogador adversário não é levado em conta na função de decisão, o que é o torna um jogador mais completo e genérico [7].

2.1.8.2.1 – APRENDIZADO POR REFORÇO

O aprendizado por reforço é uma forma de programar agentes para aprender baseado em recompensas. É um tipo de aprendizado não supervisionado. No aprendizado não supervisionado, o agente toma decisões aleatórias e registra a reação do meio ambiente, as recompensas. Existem dois tipos de aprendizados por reforço basicamente: o aprendizado passivo e o ativo. No aprendizado passivo, o agente sempre toma decisões aleatórias no período de aprendizado para obter bastante informação. Esse tipo de aprendizado normalmente demora mais para convergir para um bom resultado, mas normalmente converge para resultados melhores. No aprendizado ativo, o agente aprende utilizando o conhecimento já adquirido para tentar agir bem desde o começo. Nesse tipo de aprendizado, o agente normalmente converge mais rápido para uma boa solução, mas normalmente não converge para uma solução tão boa quanto o aprendizado passivo [20].

Porém, ainda assim, a mineração contribui de forma significativa no processo de descoberta de conhecimento, permitindo aos especialistas concentrarem esforços apenas em partes mais significativa dos dados [21].

2.2 – CONSIDERAÇÕES FINAIS

Neste capítulo foi abordada toda a parte teórica que será utilizada nesse trabalho, desde a teoria do poker aos conceitos mais importantes de *Machine Learning* e Mineração de Dados, que serão ferramentas muito utilizadas para obter os resultados esperados.

CAPÍTULO 3 - METODOLOGIA

Esse trabalho, que visa desenvolver um sistema automatizado de tomada de decisão em um jogo de poker, foi dividido em quatro etapas principais, que serão detalhadas nas seções a seguir.

3.1 – CRIAÇÃO DE UMA BASE DE DADOS COM AS POSSÍVEIS AÇÕES

A primeira etapa, foi implementar a árvore de decisões no Excel, com quatro atributos: as cartas, a quantidade de fichas, a posição e por fim as ações, baseadas nos itens anteriores e nas possíveis ações anteriores de outros jogadores.

Para a modalidade NLHE 6-máx, foram necessárias 18 planilhas, sendo uma para cada posição da mesa (totalizando seis posições), variando em três faixas de *stack* médio (10 a 20bb, 20 a 40bb e 40bb+), com 169 linhas em cada planilha (Figura 2.11), para definir bem o *range* que irá abranger todos os cenários possíveis durante o jogo. A Figura 3.1 mostra uma parte do *dataset* para a posição *Button* construído no Excel.

Figura 3.1: Construção do *dataset* no excel.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
1	Cartas	Quantidade de fichas (Big Blinds)			Posição	Ações												
2	AA		10 a 20		BU													
3	AKo		10 a 20		BU													
4	AQo		10 a 20		BU													
5	AJo		10 a 20		BU													
6	ATo		10 a 20		BU													
7	A9o		10 a 20		BU													
8	A8o		10 a 20		BU													
9	A7o		10 a 20		BU													
10	A6o		10 a 20		BU													
11	A5o		10 a 20		BU													
12	A4o		10 a 20		BU													
13	A3o		10 a 20		BU													
14	A2o		10 a 20		BU													
15	AKs		10 a 20		BU													
16	KK		10 a 20		BU													
17	KQo		10 a 20		BU													
18	KJo		10 a 20		BU													
19	KTo		10 a 20		BU													
20	K9o		10 a 20		BU													
21	K8o		10 a 20		BU													
22	K7o		10 a 20		BU													
23	K6o		10 a 20		BU													
24	K5o		10 a 20		BU													
25	K4o		10 a 20		BU													
26	K3o		10 a 20		BU													
27	K2o		10 a 20		BU													
28	AQs		10 a 20		BU													
29	KQs		10 a 20		BU													
30	QQ		10 a 20		BU													
31	QJo		10 a 20		BU													
32	QTo		10 a 20		BU													
33	Q9o		10 a 20		BU													
34	Q8o		10 a 20		BU													
35	Q7o		10 a 20		BU													
36	Q6o		10 a 20		BU													
37	Q5o		10 a 20		BU													
38	Q4o		10 a 20		BU													

Fonte: Elaborada pelo autor.

3.2 – ADAPTAÇÃO DA BASE DE DADOS PARA SER PROCESSADA

O Software Weka, não processa arquivos do tipo.xls. Mas o próprio Excel é capaz de exportar arquivos para o formato .CSV separado por vírgulas, que pode ser processado na ferramenta de classificação.

Após todas as planilhas estarem no formato .CSV, foram unificadas em apenas uma, para facilitar a análise dos resultados e para uma maior base de dados no treinamento. Foi gerado então, um arquivo .CSV com 3042 linhas (18 planilhas x 169 linhas em cada). A Figura 3.2 mostra parte da planilha unificada, aberta no bloco de notas.

Figura 3.2: Arquivo .CSV com todas as planilhas unificadas, aberto no bloco de notas.

```


Cartas,Quantidade_de_fichas_(Big_Blinds),Posição,Ações
AA,20_a_40,BB,3bet_em_raise_anterior/Call_em_All_in
AKo,20_a_40,BB,3bet_em_raise_anterior/Call_em_All_in
AKs,20_a_40,BB,3bet_em_raise_anterior/Call_em_All_in
KK,20_a_40,BB,3bet_em_raise_anterior/Call_em_All_in
QQ,20_a_40,BB,3bet_em_raise_anterior/Call_em_All_in
JJo,20_a_40,BB,3bet_em_raise_anterior/Call_em_All_in
AA,40+,BB,3bet_em_raise_anterior/Call_em_All_in
KK,40+,BB,3bet_em_raise_anterior/Call_em_All_in
QQ,40+,BB,3bet_em_raise_anterior/Call_em_All_in
AQo,20_a_40,BB,3bet_em_raise_anterior/Call_em_All_in_<=_30bb/Fold_em_3bet_pote
88o,20_a_40,BB,3bet_em_raise_anterior/Call_em_All_in_<=_30bb/Fold_em_3bet_pote
AQs,20_a_40,BB,3bet_em_raise_anterior/Call_em_All_in_<=_30bb/Fold_em_3bet_pote
TT,20_a_40,BB,3bet_em_raise_anterior/Call_em_All_in_<=_30bb/Fold_em_3bet_pote
99o,20_a_40,BB,3bet_em_raise_anterior/Call_em_All_in_<=_30bb/Fold_em_3bet_pote
AQo,40+,BB,3bet_em_raise_anterior/Call_em_All_in_<=_30bb/Fold_em_3bet_pote
AQs,40+,BB,3bet_em_raise_anterior/Call_em_All_in_<=_30bb/Fold_em_3bet_pote
99o,40+,BB,3bet_em_raise_anterior/Call_em_All_in_<=_30bb/Fold_em_3bet_pote
AKo,40+,BB,3bet_em_raise_anterior/Call_em_All_in_<=_40bb
AKs,40+,BB,3bet_em_raise_anterior/Call_em_All_in_<=_40bb
JJo,40+,BB,3bet_em_raise_anterior/Call_em_All_in_<=_40bb
TT,40+,BB,3bet_em_raise_anterior/Call_em_All_in_<=_40bb

```

Fonte: Elaborada pelo autor.

Com a planilha unificada, é possível processar o *dataset* no Weka. A Figura 3.3 mostra os dados processados, prontos para serem avaliados pelos algoritmos disponíveis no *software*.


Figura 3.3: Dados processados no Weka.




Fonte: [26].

3.3 – TREINAMENTO E VALIDAÇÃO CRUZADA DOS DADOS

Concluída a segunda etapa, foi utilizado o *software* Weka para testar diversos algoritmos classificadores para avaliar quais os que apresentariam melhor resultado. Foram testados o *training set* e o *cross-validation*, para os 43 algoritmos classificadores disponíveis na ferramenta. As Figuras 3.4 e 3.5 mostram um exemplo de treinamento e de validação cruzada, respectivamente, para o mesmo algoritmo, o *NaveBayes*.

Figura 3.4: *Training set no Weka Explorer.*

Fonte: [26].

Figura 3.5: *Cross-validation no Weka Explorer para n = 10 folds.*


Fonte: [26].

3.4 – PROGRAMAÇÃO

Finalmente, após a terceira etapa concluída, foi implementado um *bot*, nomeado *PokerBot*, com os resultados de treinamento obtidos no *Weka*, utilizando a linguagem de programação Java, no ambiente *NetBeans*.

O *PokerBot* permite que o usuário preencha qual a combinação de cartas recebida (das 169 possíveis), a quantidade de fichas (três faixas de *stack* médio) e a posição no momento da jogada, para então, retornar qual a melhor ação a ser tomada. A Figura 3.6 mostra a interface gráfica do *PokerBot*:

Figura 3.6: Interface desenvolvida para comunicação usuário/máquina.



The image shows a Java Swing window titled "PokerBot". Inside the window, there is a section labeled "Base de treinamento" with a text field containing the file path "C:\Users\Heitor\Desktop\TCC2\PlanilhaCVSvFTeste_2 - v2.csv". Below this, there are three input fields: "Cartas:" with an empty text box, "Qtde de fichas:" with a dropdown menu showing "10_a_20", and "Posição:" with a dropdown menu showing "BB". To the right of these fields is a button labeled "Training/Test". At the bottom left, there are labels "Ação:" and "Result..." without corresponding input fields.

Fonte: [30]

CAPÍTULO 4 – RESULTADOS E DISCUSSÕES

Inicialmente, a base de dados foi avaliada com a utilização do *training set*, onde alguns algoritmos tiveram desempenho de 100% de acertos, como mostra a Tabela 4.1:

Tabela 4.1: Resultado do training set para todos os classificadores.

Família	Nome	Acertos/Erros
BAYES	BayesNet	2546/496
	NaiveBayes	2326/716
	NaiveBayesMultinomial	1483/1559
	NaiveBayesUpdateable	2326/716
FUNCTIONS	Logistic	Problema para treinar
	MultilayerPerception	Problema para treinar
	SimpleLogistic	Problema para treinar
	SMO	2864/178
LAZY	IBK	3042/0
	KStar	1736/1306
	LWL	1660/1382
RULES	DecisionTable	2448/594
	JRip	1736/1306
	OneR	1685/1357
	PART	2079/963
	ZeroR	1483/1559
TREES	DecisionStump	1660/1382
	HoeffdingTree	2054/988
	J48	2050/992
	LMT	2903/139
	RandomForest	3042/0
	RandomTree	3042/0
	REPTree	2104/938
MISC	InputMappedClassifier	1483/1559
	SerializedClassifier	Problema para treinar
	AdaBoostM1	1660/1382
	AttributeSelectedClassifier	1660/1382
	Bagging	2376/666
	ClassificationViaRegression	2954/88
	CostSensitiveClassifier	Problema para treinar

META	CVParameterSelection	1483/1559
	FilteredClassifier	2054/988
	IterativeClassifierOptimizer	2033/1009
	LogitBoost	2033/1009
	MultiClassClassifier	2961/81
	MultiClassifierUpdatable	2659/383
	MultiScheme	1483/1559
	RandomCommittee	3042/0
	RandomizableClassifier	2843/199
	RandomSubSpace	1881/1161
	Stacking	1483/1559
	Vote	1483/1559
	WeightedInstanceWrapper	1483/1559

Fonte: Elaborado pelo autor.

Dos 43 classificadores utilizados, são destacados em negrito na Tabela 4.1, os que obtiveram desempenho superior a 80%, totalizando 12 classificadores. Alguns classificadores obtiveram problemas para treinar, provavelmente por falta de memória ou por não conseguir criar um modelo de treinamento para os dados analisados.

Para otimizar o trabalho, apenas os 12 classificadores com desempenho superior a 80% foram testados no *cross-validation*, visto que se um algoritmo não tem um bom desempenho no *training*, certamente não terá no *cross-validation*. A Tabela 4.2 mostra os resultados obtidos:

Tabela 4.2: Resultado do *cross-validation* para todos os classificadores com mais de 80% de acertos no *training set*.

Família	Nome	Acertos/Erros
BAYES	Bayesnet	2182/860
LAZY	IBK	1687/1355
META	ClassificationViaRegression	2287/755
	MultiClassClassifier	1663/1379
	MultiClassClassifierUpdateable	2079/963
	RandomCommittee	2056/986
	RandomizableFilteredClassifier	1240/1802
TREES	DecisionTable	1982/1014
	LMT	2131/911
	RandomForest	2106/936

	RandomTree	1905/1137
FUNCTIONS	SMO	Problema pra treinar

Fonte: Elaborado pelo autor.

Ao analisar os dados da Tabela 4.2, nota-se que nenhum classificador obteve desempenho de 100% no *cross-validation*, como obtido em quatro classificadores no *training set*. Como a intenção é que o *PokerBot* consiga executar 100% das ações pré-definidas pelo autor (74 ações ao todo), foi escolhido usar o *training set* na construção do *bot*.

Desde o início dos testes, o algoritmo com melhor desempenho nos treinamentos foi o IBK, obtendo êxito tanto nas planilhas separadas quanto na unificada. Por esse motivo, foi o algoritmo utilizado para o desenvolvimento do *PokerBot*. O algoritmo IBK é uma versão do algoritmo de clusterização k-NN (*k-nearest neighbor*) utilizado em tarefas de clusterização. Esse método representa cada instância como um ponto de dado em um espaço d-dimensional, onde d é o número de atributos. Dada uma nova instância, calcula-se a sua proximidade com o resto dos pontos de dados no conjunto de treinamento, usando medidas de proximidade, tais como a distância euclidiana. Os k vizinhos mais próximos de uma instância z são classificados como sendo da mesma classe de z [28].

Para testar o *PokerBot*, foi utilizado o *software* de poker mais tradicional no mundo, chamado *PokerStars*. Para todas as posições da mesa, e em todas as faixas de stack, o *bot* conseguiu retornar as ações a serem tomadas. O exemplo do funcionamento é mostrado nas Figuras 4.1 e 4.2:

Figura 4.1: Funcionamento do PokerBot.



Fonte: Adaptado de [10].

Figura 4.2: Resultado de uma mão que foi decidida pelo *PokerBot*.



Fonte: Adaptado de [10].

No exemplo de funcionamento mostrado acima, a decisão tomada foi: *call* em *all in* de qualquer posição. Nesse caso, foi pago um *all in* de 15 *binds* da posição SB enquanto o *bot* estava na posição BB. O resultado mostrado, é de que o *bot* ganhou o *all in* e dobrou suas fichas com a decisão.

CAPÍTULO 5 – CONCLUSÕES, CONTRIBUIÇÕES DESTE TRABALHO E TRABALHOS FUTUROS

Com o desenvolvimento desse trabalho, foi possível notar que o poker é um jogo bem desafiador para se criar um bom jogador, pois não existe um método ótimo de vencer, permitindo assim o uso de diversas técnicas diferentes e adaptações na tomada de decisão para chegar a um bom resultado.

É possível, uma pessoa que não tem conhecimento específico na área utilizar o jogador inteligente para jogar poker, e até mesmo pessoas com experiência poderão melhorar seu desempenho com o uso do programa que foi desenvolvido.

Para trabalhos futuros, pode-se analisar a possibilidade de desenvolver um jogador inteligente para pós-*flop*, o que seria extremamente complexo, devido à quantidade de combinações possíveis com cinco cartas em um baralho com cinquenta e duas cartas.

GLOSSÁRIO

3bet	Reaumento depois de uma aposta e um aumento
3bet-light	Um reaumento com uma mão fraca
4bet	Um reaumento depois de uma aposta, um aumento e um reaumento
Ação	A vez de um jogador agir na mesa
Agressor	O jogador que começou apostando
All-in	Apostar todas as fichas
Bet	Apostar
Big Blind	Este jogador coloca 1 blind obrigatório antes de receber as cartas
Bluff	Blefe
Button	É o último jogador a agir na mão
Call	Pagar uma aposta
Check	Passar a vez
Coin Flip	Situação onde um par joga contra duas <i>over card</i>
Connector	Cartas consecutivas
Cutoff	Posição anterior ao jogador do botão
Deep Stack	Quando os jogadores possuem uma quantidade elevada de <i>Big Blind</i>
Edge	Vantagem técnica sobre outros jogadores
Equidade	Probabilidade de sua mão vencer na rodada
Expected Value	Expectativa matemática de ganha ou perda de uma jogada
Field	Conjunto de jogadores que jogam determinado torneio
Flop	As primeiras três cartas comunitárias distribuídas na mesa
Flush	Combinação de cinco cartas do mesmo naipe
Fold	Desistir das cartas na rodada de aposta
Full house	Combinação de uma trinca e um par
Full hing	Mesa com 9 ou 10 jogadores
Gap	Quando todos os jogadores desistem até a sua vez
Hold'em	A modalidade de poker mais praticada no mundo

Late Position	São as últimas posições na rodada de apostas
Limit	Apostas limitadas
Limp	O primeiro jogador apenas iguala a aposta mínima <i>pré flop</i>
No Limit	Sem limite de apostas
Offsuited	Cartas de naipes diferentes
Pré flop	Primeira rodada de apostas antes das cartas comunitárias serem viradas
Push	Giria da expressão All-in
Quadra	Quatro cartas do mesmo valor
Raise	Aumentar a aposta
Range	Um grupo de mãos
Re-raise	Reaumento na aposta
Re-steal	Aumentar a aposta em cima de um jogador que está tentando blefar
River	Última carta comunitária a ser distribuída
Royal Flush	Sequência de T a A do mesmo naipe
Sharkscope	Site com resultado de jogadores
Small Blind	Aposta obrigatória de meio <i>blind</i> colocada pelo jogador a esquerda do botão
Stack	Todas as fichas do jogador
Straight	Cinco cartas em sequência
Straight Flush	Cinco cartas em sequência e do mesmo naipe
Suited	Duas cartas do mesmo naipe
Suited Connector	Duas cartas em sequência e do mesmo naipe
Turn	É a quarta carta comunitária distribuída
Under The Gun	É o primeiro jogador a agir
Variância	Variação positiva ou negativa do <i>bankroll</i> de um jogador

REFERÊNCIAS

- [1] UOL ESPORTE. **Pôquer é oficializado como esporte mental e passa a ter status do xadrez.** São Paulo, 2010. Disponível em: <<https://esporte.uol.com.br/ultimas-noticias/2010/04/30/poquer-e-reconhecido-como-esporte-mental-e-fica-com-mesmo-status-do-xadrez.jhtm>>. Acesso em: 07 de maio de 2018.

- [2] BELLO, L. **Poker em 50 lições rápidas e fáceis.** Rio de Janeiro: Agir, 2012.

- [3] SKLANSKY, D. **Teoria do Poker.** Belo Horizonte: Raise, 2011.

- [4] ELIAS, P. S. **Algoritmos e inteligência artificial exigem atenção do Direito.** Conjur, 2017. Disponível em: < <https://www.conjur.com.br/2017-nov-20/paulo-sa-elias-inteligencia-artificial-requer-atencao-direito>> . Acesso em: 25 de abr. de 2018.

- [5] BARONI, L.; WHILE, L. **Adaptative Learning for Poker.** The University of Western Australia, Western Australia, 2000.

- [6] SHARKSCOPE. Player Statistics. Sharkscope, 2018. Disponível em: <<https://pt.sharkscope.com/#PlayerStatistics/networks/Player%20Group/players/HeC>>. Acesso em 1 de out. de 2018.

- [7] FAZIO, V. S. **Algoritmos para um jogador inteligente de poker.** Universidade Federal de Santa Catarina, Florianópolis, 2008. Disponível em: <https://projetos.inf.ufsc.br/arquivos_projetos/projeto_773/tcc%20final%20e%20artigo.pdf>. Acesso em: 01 de maio de 2018.

- [8] FREITAS, R. **Poker não para de crescer e vai conquistar você.** Administradores, 2017. Disponível em: <<https://www.administradores.com.br/noticias/negocios/o-poker-nao-para-decrescer-e-vai-conquistar-voce/120551/>>. Acesso em: 01 de maio de 2018.

- [9] LUGER, G. F.; STUBBLEFIELD, W. A. **Artificial Intelligence: Structures and Strategies for Complex Problem Solving.** Harlow, England: Addison Wesley Longman, Inc., 1998.

[10] POKERSTARS. **No Limit Texas Holde'm**. Ilha de Man, 2014. Disponível em: <<https://www.pokerstars.com/br/poker/games/texas-holdem/#/no-limit>>. Acesso em: 06 de jun. de 2018.

[11] GORDON, Phill. **Advanced Lessons for Mastering Poker 2.0**. Nova Iorque: Simon & Schuster, 2011.

[12] Max Value Software. **PokerTracker**, versão 4.15.13: PockerTracker 4 - Database. Max Value corporation, 2018.

[13] Poker Harder. **Ranking das Mãos – Melhores mãos no poker**. Disponível em: <<http://www.pokerharder.com/br/aprender-poker/ranking-maos-poker/>>. Acesso em: 06 de jun. de 2018.

[14] BARRAT, G. **7 Short Stack Poker Tips for Maximizing Your Earnings**. UpSwingPoker, 2018. Disponível em: <<https://upswingpoker.com/short-stack-poker-tips/>>. Acesso em: 17 de out. de 2018.

[15] MULLER, M. **A Jornada de um Pro: Stacks e Estratégias**. Poker Dicas, 2016. Disponível em: <<https://pokerdicas.com/estrategia/estrategia-iniciante/a-jornada-de-um-pro-stacks-e-estrategias/>>. Acesso em: 19 de out. de 2018.

[16] FINDLER, Nicholas V. **Studies in Machine Cognition Using the Game of Poker**. State University Of New York At Buffalo: R. J. Hanson, 1977.

[17] COPPIN, Ben. **Inteligência artificial**. Rio de Janeiro: LTC, 2010.

[18] SANTOS, Cícero. **Aprendizado de máquina na identificação de sintagmas nominais: o caso do português brasileiro**. Rio de Janeiro, 2005.

[19] MONACO, J. **10 Algoritmos de Machine Learning que você precisa conhecer**. Semantix, 2017. Disponível em: <<http://www.semantix.com.br/blog/10-algoritmos-de-machine-learning>>. Acesso em: 06 de jun. 2018.

[20] SUTTON, Richard S.; BARTO, Andrew G. **Reinforcement Learning: An Introduction**. Stanford University, 2015.

[21] CAMILO, C.; O. DA SILVA, J. C. **Mineração de Dados: Conceitos, Tarefas, Métodos e Ferramentas**. Universidade Federal de Goiás, 2009.

[22] HAND, D.; MANNILA, H.; SMYTH, P. **Principles of Data Mining**. MIT Press, 2001.

[23] CABENA, P.; HADJINIAN, P.; STADLER, R.; JAAPVERHEES; ZANASI, A. **Discovering Data Mining: From Concept to Implementation**. Prentice Hall, 1998.

[24] FAYYAD, U.; PIATETSKY-SHAPIO, G.; SMYTH, P. **From Data Mining to Knowledge Discovery in Databases**. American Association for Artificial Intelligence, 1996.

[25] LAROSE, D. T. **Discovering Knowledge in Data: An Introduction to Data Mining**. John Wiley and Sons, Inc, 2005.

[26] WEKA Software. **Waikato Environment for Knowledge Analysis**, versão 3.8.2. The University of Waikato, Nova Zelândia, 2017.

[27] REVOREDO, K.; PAES, A.; ZAVERUCHA, G.; COSTA, V.S. **Revisando Redes Bayesianas através da Introdução de Variáveis Não-observadas**. Universidade Federal do Rio de Janeiro, 2009.

[28] WITTEN, H.; FRANK, E.; HALL, M. **DATA MINING: Practical Machine Learning Tools and Techniques**. 3º Edition, United States: Elsevier, 2011.

[29] AMARAL, L. R.; RODRIGUES, F. A. **Aplicação de Métodos Computacionais de Mineração de Dados na Classificação e Seleção de Oncogenes Medidos por Microarray**. Researchgate, 2012. Disponível em: <
https://www.researchgate.net/profile/Laurence_Amaral/publication/290396158_Aplicacao_de_Metodos_Computacionais_de_Mineraacao_de_Dados_na_Classificacao_e_Selecao_de_Oncogenes_Medidos_por_Microarray_Oncogenes_Classification_Measured_by_Microarray_using_Data_Mining_Computational/links/5696ed3c08ae34f3cf1de9b8.pdf>. Acesso em: 20 de out. 2018.

[30] NetBeans IDE. **NetBeans Integrated Development Environment**, versão 8.2. Oracle Corporation, 2012.